

Redes Neurais Convolucionais

Arthur Abrahão Santos Barbosa
Universidade Federal de Pernambuco
Centro de Informática
Pernambuco, Brasil
aasb2@cin.ufpe.br

Filipe Samuel da Silva
Universidade Federal de Pernambuco
Centro de Informática
Pernambuco, Brasil
fss8@cin.ufpe.br

I. OBJETIVOS

A. Objetivo Geral

Desenvolver um Classificador Multiclasse que reconheça as imagens do dataset CIFAR100 [1].

B. Objetivos Específicos

- Compreender a implementação de uma Rede Neural Convolucional
- Demonstrar a Importância do Aprendizado Profundo e suas aplicações
- Demonstrar a eficiência de três arquiteturas importantes para a história do Deep Learning

II. JUSTIFICATIVA

Este projeto foi escolhido com base no fato deste dataset ser bastante usado para testar redes neurais com imagens coloridas, e pelo fato de ter uma divisão bastante equilibrada dos dados. [1].

Sua função é verificar a qual das classes pertence uma imagem de tamanho 32x32.

III. BASE DE DADOS

IV. ANÁLISE EXPLORATÓRIA DOS DADOS

A. Descrição Estatística dos dados

B. Sobre o Projeto

V. SOBRE AS MÉTRICAS UTILIZADAS

A. Precision

Precision é a razão

$$\frac{A_c}{A_c + A_e} \quad (1)$$

onde:

- A_c é o número de amostras corretamente classificadas de uma determinada classe.
- A_e é o número de amostras erroneamente classificadas como sendo desta determinada classe.

Precision é intuitivamente a habilidade do classificador não marcar como pertencente a uma classe uma amostra que não pertence a esta. O melhor valor de Precision é 1 e o pior é zero. [2]

B. Accuracy

Accuracy é a fração de amostras preditas corretamente, e é dada pela seguinte fórmula:

$$\frac{\sum_{c=1}^n A_c}{\sum_{t=1}^n A_t} \quad (2)$$

onde:

- n é o número de classes
- A_c é o número de amostras corretamente classificadas de uma determinada classe.
- A_t é o número de amostras que pertencem a uma determinada classe

[3]

C. Recall-Score

O Recall Score é a razão:

$$\frac{A_c}{A_t} \quad (3)$$

onde:

- A_c é o número de amostras classificadas corretamente de uma determinada classe
- A_t é o número de amostras que pertencem a esta classe

O Recall Score é intuitivamente a habilidade do classificador de encontrar todas as amostras pertencentes a uma classe específica. O melhor valor do Recall Score é 1 e o pior valor é 0. [4]

D. F1-Score

O F1 Score pode ser interpretado como a média ponderada da precisão e recall. O melhor valor que o F1 score pode alcançar é 1, o pior é 0. A contribuição relativa da precisão e recall para o F1 score são iguais. A fórmula para o F1 score é:

$$F1 = \frac{2 \cdot (precision \cdot recall)}{precision + recall} \quad (4)$$

[5]

E. Confusion Matrix

No caso de classificação multiclasse, uma confusion matrix é dividida em $N \times N$ categorias (onde N é o número de classes do problema), cada uma apresentando a quantidade de amostras que se encaixam nesta. A diagonal do meio representa a quantidade de amostras classificadas corretamente e as demais seções da matriz demonstram o número de amostras classificados erroneamente, a quais classes eles pertencem e em quais classes eles foram classificados.

[6]

VI. REDES NEURAIS CONVOLUCIONAIS

A. AlexNet

B. GoogLeNet

C. Squeezenet

VII. EXPERIMENTOS

A. Experimentos Iniciais

B. CIFAR10

C. Similaridade de Pixel

D. Treinando os Modelos

E. Imagens em Grayscale

F. Sem Normalização e sem Data Augmentation

G. Apenas um Epoch

H. Limitando os Dados

I. Modelos Pré-Treinados

VIII. ANÁLISE DOS RESULTADOS

IX. CONCLUSÕES E DISCUSSÕES

REFERENCES

- [1] A. Krizhevsky. (2009) Cifar-10 and cifar-100 datasets. [Online]. Available: <https://www.cs.toronto.edu/~kriz/cifar.html>
- [2] "sklearn.metrics.precision_score." [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_score.html
- [3] A. Long, "Understanding data science classification metrics in scikit-learn in python," Aug. 2018. [Online]. Available: <https://towardsdatascience.com/understanding-data-science-classification-metrics-in-scikit-learn-in-python-3bc336865019>
- [4] "sklearn.metrics.recall_score." [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.recall_score.html
- [5] sklearn.metrics.f1_score. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html
- [6] B. Shmueli, "Multi-class metrics made simple, part i: Precision and recall," Jul. 2019. [Online]. Available: <https://towardsdatascience.com/multi-class-metrics-made-simple-part-i-precision-and-recall-9250280bddc2>
- [7] A. Krizhevsky, "Learning multiple layers of features from tiny images," University of Toronto, Toronto, Ontario, Tech. Rep. 0, 2009.
- [8] Muthu, "Understanding the classification report through sklearn," Jul. 2018. [Online]. Available: <https://muthu.co/understanding-the-classification-report-in-sklearn/>